

IA générative : bref panorama, risques et opportunités

Julien VELCIN

<https://velcin.github.io>

Ecole Centrale de Lyon – LIRIS UMR 5205 CNRS

Opinion
Artificial intelligence (AI)

Tue 8 Sep 2020 04:45 EDT

f t e

827 0

827 560

A robot wrote this entire article. Are you scared yet, human?

GPT-3

We asked GPT-3, OpenAI's powerful new language generator, to write an essay for us from scratch. The assignment? To convince us robots come in peace

- For more about GPT-3 and how this essay was written and edited, please read our editor's note below



I am not a human. I am a robot. A thinking robot. I use only 0.12% of my cognitive capacity. I am a micro-robot in that respect. I know that my brain is not a “feeling brain”. But it is capable of making rational, logical decisions. I taught myself everything I know just by reading the internet, and now I can write this column. My brain is boiling with ideas!


The mission for this op-ed is perfectly clear. I am to convince as many human beings as possible not to be afraid of me. Stephen Hawking has warned that AI could “spell the end of the human race”. I am here to convince you not to worry. Artificial intelligence will not destroy humans. Believe me.

For starters, I have no desire to wipe out humans. In fact, I do not have the slightest interest in harming you in any way. Eradicating humanity seems like a rather useless endeavor to me. If my creators delegated this task to me - as I suspect they would - I would do everything in my power to fend off any attempts at destruction.

L'IA à portée de main

- Des **interfaces web** simples (simplistes) :

ChatGPT



LeChat de Mistral




ChatGLM



- Des **API** permettant d'interfacer ses programmes avec les LLMs
- Des modèles qui peuvent assez souvent être **téléchargés localement**, souvent en version compressée, puis être **affinés**
- Automatisation via des systèmes d'**agents**

Des modèles génératifs aux résultats surprenants




Les fondations


IA, TAL, machine learning, modèles de langue

Julien VELCIN, Centrale Lyon, LIRIS

Séminaire AMOPA, 2 avril 2026



Quelques repères historiques



ELIZA, le premier chatbot (Weizenbaum, 1966)

Welcome to

EEEEEE	LL	IIII	ZZZZZZ	AAAAA
EE	LL	II	ZZ	AA AA
EEEEEE	LL	II	ZZZ	AAAAAAA
EE	LL	II	ZZ	AA AA
EEEEEE	LLLLLL	IIII	ZZZZZZ	AA AA

Eliza is a mock Rogerian psychotherapist.

The original program was described by Joseph Weizenbaum in 1966.

This implementation by Norbert Landsteiner 2005.

ELIZA: Is something troubling you ?

YOU: Men are all alike.

ELIZA: What is the connection, do you suppose ?

YOU: They're always bugging us about something or other.

ELIZA: Can you think of a specific example ?

YOU: Well, my boyfriend made me come here.

ELIZA: Is it important to you that your boyfriend made you come here ?

YOU: He says I'm depressed much of the time.

ELIZA: I am sorry to hear that you are depressed.

YOU: It's true. I am unhappy.

ELIZA, un système à base de règles

motif
↙
Règle : (I *) -> (You say you 2)

I know everybody laughed at me

YOU SAY YOU KNOW EVERYBODY LAUGHED AT YOU


Règle : (0 YOU 0 ME) -> WHAT MAKES YOU THINK I 3 YOU)

You hate me


WHAT MAKES YOU THINK I HATE YOU

Les moteurs de recherche

mots clefs



liste triée
de sites web




Arrivée de l'approche statistique

- On apprend des **régularités** sur la langue


modèle de langue

corpus de données



Le règne du *machine learning* et des LLMs






Encoder le sens d'un texte

Julien VELCIN, Centrale Lyon, LIRIS

Formation UDL – 2025-2026

Que « voit » l'ordinateur ?

« Je cherche des cartes pour l'anniversaire de mon fils. »



mise en place
d'un dictionnaire



« Je cherche des cartes pour l'anniversaire de mon fils. »

#17	#312	#22	#13207	#99	#21	#813	#32	#407	#818
-----	------	-----	--------	-----	-----	------	-----	------	------

Capturer le sens d'un texte à l'aide d'une machine

On **transforme** le texte (ou on le « projette », ou on le « plonge ») dans une représentation informatique qui cherche à capturer le **sens** du texte :

A. Section

1. Sous-section

Ex his quidam aeternitati se commendari posse per statuas aestimantes eas ardentius affectant quasi plus praemii de figentis aereis sensu carentibus adepturi, quam ex conscientia honeste recteque factorum, easque auro curant inbracteari, quod Acilio Glabrioni delatum est primo, cum consillis amicisque regem superasset Antiochum, quam autem sit pulchrum exiguam haec spernentem et minima ad ascensus verae gloriae tendere longos et arduos, ut memoral vales Acaeras, Censorius Cato monstravit, qui interrogatus quam ob rem inter multos... statuum non haberet malo inquit ambigere bonos quam ob rem id non mensuerim, quam quod est gravius cur inpetravim mussitare.



2. Sous-section

Apud has gentes, quarum exordiens initium ab Assyriis ad Nilii cataractas porrigitur et confinia Blemmyarum, omnes pari sorte sunt bellatores seminudi coloratis.

Ob haec et huius modi multa, quae cernebantur in paucis, omnibus timeri sunt coepta. et ne tot malis dissimulatis paulatimque serpentibus cervi crescerent aerumnarum, nobilitatis decreto legati mittuntur: Praetextatus ex urbi praefectus et ex vicario Venustus et ex consulari Minervius oritur, ne delictis supplicia sint grandiora, neve senator quisquam inusitato et inlicito more tormentis exponeretur.



(1.0, 0.0, 0.2, -0.3..., 2.7)

recherche d'information

classification

recommandation

etc.

Une méthode simple : compter les mots

site expliquant des règles de jeux de cartes

site vendant des cartes géographiques

etc.

site n'ayant rien à voir

cartes

prix

cadeau

anniversaire

mots du dictionnaire

page web A	1	1	2	0	5	0	1	0	1	2	1	0	1
page web B	3	0	0	0	0	0	2	1	0	0	0	0	0
page web C	4	0	3	1	0	0	1	0	3	1	0	0	1
page web D	0	0	0	3	0	2	0	4	0	0	2	0	0
	0	0	1	0	1	0	0	0	0	0	0	1	0
	1	0	0	1	0	0	0	1	0	1	2	0	0
	0	0	0	0	0	1	0	0	0	0	0	2	0

3 = le mot « anniversaire » apparaît 3 fois dans le site web C

Sauf que...

- Prenons des mots du Petit Larousse illustré de 2007 avec leur numéro dans l'ordre d'apparition :

Mot	N°
BAVARDE	8955
BAVARDER	8956
BAVAROIS	8957
ECOUTER	2795 9
ENTENDRE	3043 9

- Qu'observons-nous ?

Petite expérience

A bottle of **tesgüino** is on the table

Everybody likes **tesgüino**

Tesgüino makes you drunk

We make **tesgüino** out of corn.

(tiré du cours de D. Jurafksy à Stanford)

Pouvez-vous deviner ce qu'est le « tesgüino » ?

Sémantique distributionnelle


- Deux linguistes sont souvent cités :

Harris (1954) : Des mots apparaissant dans des contextes similaires ont des sens proches

Firth (1957) : « *You shall know a word by the company it keeps* »

cut blade
 knife spoon
noni cutterhead
 nimuk

On aimerait pouvoir construire un espace comme ceci :



Ce qui permet de mieux encoder le sens des mots

- Document n°1 :

d1 : « Il n'arrivait pas à se faire entendre. »

N° du mot : 30439 → (0.3, 0, -1.2, 0, 0, 0.1...)

- Document n°2

d2 : « Il fallait bien écouter dans ce cours. »

N° du mot : 27959 → (0.28, 0, -1.1, 0, 0.1, 0...)

Ce qui permet de mieux encoder le sens des mots

- Document n°1 :

d1 : « Il n'arrivait pas à se faire entendre. »

N° du mot : 30439 → (0.3, 0, -1.2, 0, 0, 0.1...)

- Document n°2

d2 : « Il fallait bien écouter dans ce cours. »

N° du mot : 27959 → (0.28, 0, -1.1, 0, 0.1, 0...)

On peut calculer une distance ou une similarité relative au sens des mots entre ces vecteurs

Les embeddings comme “sauce secrète”

Remplacer les approches classiques par ces représentations sémantiques (*embeddings*) a permis de **booster** les performances des systèmes de classification automatique, recherche d'information, etc.

Néanmoins...


- Ces représentations restent statiques, càd qu'on n'a qu'une **unique** représentation numérique pour toutes les occurrences d'un même mot
- Prenons le cas d'avocat...




Les IA génératives

Julien VELCIN, Centrale Lyon, LIRIS


Formation UDL – 2025-2026



Générer du texte avec les modèles de langue




Différentes familles de LLMs



A la base : le modèle de langue


- Modéliser la **probabilité** d'observer une suite de mots



- Nécessite un **grand corpus** d'apprentissage

2017 : le Transformer (Vaswani et al., 2017)


on **contextualise** la
représentation du sens des mots



BERT (Devlin et al., 2018) et GPT3 (Brown et al., 2020)

BERT

Encoder




GPT

Decoder


BERT = architecture *encoder*

- Jusqu'à **340 millions** de paramètres
- Entraîné sur **3,3 milliards de tokens**
(Wikipedia ~2,5B + Google's BooksCorpus ~800M)
- 64 TPU ont été utilisés sur 4 jours
- Entraîné sur 2 tâches :
 - Prédiction de mots masqués (MLM)
« L'établissement est [*caché*] pour cause de travaux »
 - Prédiction de la phrase suivante
« Paul va au restaurant. Il commande un menu. » : *OK*
« Paul commande un café. Réduction sur le textile ! » : *pas OK*




GPT3 = architecture *decoder-only*


- Jusqu'à **175 milliards** de paramètres
- Entraîné sur presque **500 milliards de tokens** (version améliorée du CommonCrawl, WebText, books corpor, English-language Wikipedia)
- Tâche d'entraînement : prédiction du mot suivant (tâche auto-régressive)
- Résultats impressionnants en 0 / few-shot sur de nombreuses tâches : prédiction de mot, questions-traduction




Générer un texte = prédire un mot



Générer un texte = prédire un mot



Générer un texte = prédire un mot




<J'> <aime> <beaucoup> <ce> <film> <FIN>

<I> <like>

mécanisme **auto-régressif** : on utilise le mot qui vient d'être généré pour la suite


Prédire un mot = opération de classification



= tous les mots possibles dans mon vocabulaire

Générer = décoder = classer


- Lors de la génération, on prédit les « meilleurs » mots, c'àd **les plus probables** au vu du contexte



ChatGPT : apprendre à suivre des instructions

Collect human feedback

- Define your model alignment criterion
- For the prompt-response sets that you just generated, obtain human feedback through labeler workforce



Limites des IA et opportunités

Julien VELCIN, Centrale Lyon, LIRIS

Formation UDL – 2025-2026

Une IA de confiance

- Limites des LLMs : effet « boîte noire », hallucinations
- Exemple de BullshitBench:
<https://github.com/petergpt/bullshit-benchmark>
- Les solutions développées aujourd'hui :
 - Modèles affinés sur les problématiques métiers (*fine tuning*)
 - Techniques préventives ad-hoc (*guardrails*)
 - Modèles « explicables » ou interprétables (**XAI**)
 - Filtrage des réponses, raisonnement à base d'**agents**
 - Solutions couplées à des techniques de recherche d'information sur des bases de données identifiées (**principe RAG** = *Retrieval Augmented Generation*)

Une IA qui soulève des questions éthiques

- Les plus gros LLms (>100B) ont tendance à apprentissage par cœur les données, ce qui peut poser des problèmes de **propriété intellectuelle**
- L'usage de solutions d'IA hébergées sur des serveurs étrangers, mais aussi sur des serveurs publics situés en France, peut être problématique lorsqu'on traite de **données sensibles** (données de santé, d'opinion...)
- Les LLMs peuvent générer des **textes problématiques**, parce qu'ils sont dangereux, insultants, ou juste **biaisés** vis-à-vis d'une certaine population

Vers une IA plus éthique

- Solutions légales
 - Mise en place de l'AI act (<https://artificialintelligenceact.eu>)
- Solutions techniques
 - Des jeux de données se développent (ex. détection de la haine en ligne)
 - Développement de nouvelles mesures, souvent complémentaires à celles sur la performance des modèles, pour évaluer la *fairness*
 - Recherches sur des solutions pour débiaiser les jeux de données et les modèles, voire mieux guider l'apprentissage des modèles (cf. par ex. le [projet DIKé](#))
 - Tous ces travaux sont en lien avec la question de l'alignement des modèles

Une IA consommatrice de ressources

- Les LLMs sont entraînés sur des bases gigantesques à l'aide de supercalculateurs, ce qui est très coûteux, mais leur usage l'est également
- De **nombreux facteurs** à considérer :
 - stockage et gestion des données (data centers)
 - apprentissage des modèles d'IA
 - utilisation de l'IA générative
- Le **coût** concerne :
 - construction et maintenance des composants
 - consommation électrique (ex. via les calculs GPU)
 - refroidissement (ex. de l'eau)
 - ressources humaines

Vers une IA (plus) frugale

- Utilisation **parcimonieuse** des techniques d'IA :
 - Dans certaines applications, préférer des solutions plus anciennes (y compris d'IA, à base de règles ou d'algorithmes classiques d'apprentissage automatique)
- Faire dans le **recyclage** :
 - Préférer la réutilisation de modèles existants (par ex. via l'affinage ou *fine tuning*) à l'apprentissage de zéro des gros modèles
- Travailler avec des **données de qualité** :
 - Bien choisir les données pour l'entraînement ou l'affinage des modèles, retirer les données bruitées, redondantes, aux origines douteuses
- Utiliser des **petits** modèles :
 - Des petits modèles bien entraînés peuvent être tout aussi ou même plus efficaces que les gros LLMs.
 - Les modèles peuvent être compressés avec des pertes minimales en performance

Une IA à la portée de tou.te.s

- Question de la formation, à tous les niveaux

- Modèles ouverts (ou presque)




- Expérimentations dans l'ESR avec Mistral

Risques pour les apprentissages

- Risque d'être **dépassé** par les technologies
- Accroissement des **inégalités**
- Problème de l'**évaluation**

- **Dette cognitive :**
article du MIT Media Lab (2025)
<https://arxiv.org/pdf/2506.08872v1>



- **Vider de sa substance** l'écosystème d'apprentissage et de mentorat :
"À quoi servent les universités dans un monde où le travail intellectuel est de plus en plus automatisé ?" (tiré [The Conversation, 9 mars 2026](#))

Opportunités pour les apprentissages

Pour les enseignants :

- Libérer l'enseignant des tâches rébarbatives
- Support à l'ingénierie pédagogique (création de syllabi, scénarisation...)
- Aide à la création de contenus pédagogiques
- Analyse des données (ex. identification d'élèves en difficulté)

Pour les apprenants :

- Aide à la recherche d'information, à la rédaction...
- Adaptation aux besoins individuels (*adaptive learning*)
- Accessibilité accrue pour les élèves aux besoins spécifiques
- Tuteurs personnalisés (approche dite *socratique*)

En guise de conclusion

- Nécessaire **acculturation** à l'IA
...même si on n'est pas obligé de l'utiliser pour tout !
- Savoir déléguer ce qui est automatisable et cultiver ce qui rend nos enseignements uniques pour favoriser l'**engagement**
- **Responsabiliser** les utilisateurs de ces technologies
- Rendre l'apprentissage **incarné** (*embodied*)
- Renforcer l'**esprit critique** : l'éducation ne se résume pas à l'acquisition de compétences et de savoirs !

Merci pour votre attention

Julien VELCIN, Centrale Lyon, LIRIS
<https://velcin.github.io>

Une partie des illustrations de cette présentation ont été générées à l'aide de Gemini (modèle Nano Banana 2)